

**ИНТЕЛЛЕКТ ➤**

# Альтернативы классическому трансформеру (вниманию), SSM, Mamba, DeltaNet

к.ф.-м.н. Тихомиров Михаил Михайлович

старший научный сотрудник  
НИВЦ МГУ имени М. В. Ломоносова




# Проблема классического внимания

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

$O(N^2)$

**Количество вычислений растёт  
квадратично от длины  
последовательности**






# KV-кэш

- Чтобы не считать на каждом новом токене все KV, который не зависят от “будущего”
- Возникает **линейная зависимость памяти** от длины контекста
- На один токен ~

$$2 \cdot 2 \cdot n_{\text{layers}} \cdot n_{\text{heads}} \cdot d_{\text{head}}$$




# Дилемма компрессии контекста



Мощь (Effectiveness) vs Скорость (Efficiency)






# Пути борьбы с квадратом



**Гипотеза:** матрица  $P$  - низкоранговая  $\rightarrow$  можно ускорить вычисление внимания, за счет предварительной проекции  $K$  и  $V$  в более низкоранговые.

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V) = \underbrace{\text{softmax} \left[ \frac{QW_i^Q (KW_i^K)^T}{\sqrt{d_k}} \right]}_P VW_i^V,$$



$$\begin{aligned} \overline{\text{head}}_i &= \text{Attention}(QW_i^Q, E_iKW_i^K, F_iVW_i^V) \\ &= \underbrace{\text{softmax} \left( \frac{QW_i^Q (E_iKW_i^K)^T}{\sqrt{d_k}} \right)}_{\bar{P}: n \times k} \cdot \underbrace{F_iVW_i^V}_{k \times d} \end{aligned}$$





# Linformer

| $n$  | Model                              | SST-2       | IMDB        | QNLI        | QQP         | Average      |
|------|------------------------------------|-------------|-------------|-------------|-------------|--------------|
| 512  | Liu et al. (2019), RoBERTa-base    | 93.1        | 94.1        | 90.9        | <b>90.9</b> | 92.25        |
|      | Linformer, 128                     | 92.4        | 94.0        | 90.4        | 90.2        | 91.75        |
|      | Linformer, 128, shared kv          | <b>93.4</b> | 93.4        | 90.3        | 90.3        | 91.85        |
|      | Linformer, 128, shared kv, layer   | 93.2        | 93.8        | 90.1        | 90.2        | 91.83        |
|      | Linformer, 256                     | 93.2        | 94.0        | 90.6        | 90.5        | 92.08        |
|      | Linformer, 256, shared kv          | 93.3        | 93.6        | 90.6        | 90.6        | 92.03        |
| 512  | Linformer, 256, shared kv, layer   | 93.1        | 94.1        | <b>91.2</b> | 90.8        | <b>92.30</b> |
|      | Devlin et al. (2019), BERT-base    | 92.7        | 93.5        | 91.8        | 89.6        | 91.90        |
|      | Sanh et al. (2019), Distilled BERT | 91.3        | 92.8        | 89.2        | 88.5        | 90.45        |
| 1024 | Linformer, 256                     | 93.0        | 93.8        | 90.4        | 90.4        | 91.90        |
|      | Linformer, 256, shared kv          | 93.0        | 93.6        | 90.3        | 90.4        | 91.83        |
|      | Linformer, 256, shared kv, layer   | 93.2        | <b>94.2</b> | 90.8        | 90.5        | 92.18        |


| length $n$ | projected dimensions $k$ |      |      |      |      | length $n$ | projected dimensions $k$ |      |      |      |      |
|------------|--------------------------|------|------|------|------|------------|--------------------------|------|------|------|------|
|            | 128                      | 256  | 512  | 1024 | 2048 |            | 128                      | 256  | 512  | 1024 | 2048 |
| 512        | 1.5x                     | 1.3x | -    | -    | -    | 512        | 1.7x                     | 1.5x | -    | -    | -    |
| 1024       | 1.7x                     | 1.6x | 1.3x | -    | -    | 1024       | 3.0x                     | 2.9x | 1.8x | -    | -    |
| 2048       | 2.6x                     | 2.4x | 2.1x | 1.3x | -    | 2048       | 6.1x                     | 5.6x | 3.6x | 2.0x | -    |
| 4096       | 3.4x                     | 3.2x | 2.8x | 2.2x | 1.3x | 4096       | 14x                      | 13x  | 8.3x | 4.3x | 2.3x |
| 8192       | 5.5x                     | 5.0x | 4.4x | 3.5x | 2.1x | 8192       | 28x                      | 26x  | 17x  | 8.5x | 4.5x |
| 16384      | 8.6x                     | 7.8x | 7.0x | 5.6x | 3.3x | 16384      | 56x                      | 48x  | 32x  | 16x  | 8x   |
| 32768      | 13x                      | 12x  | 11x  | 8.8x | 5.0x | 32768      | 56x                      | 48x  | 36x  | 18x  | 16x  |
| 65536      | 20x                      | 18x  | 16x  | 14x  | 7.9x | 65536      | 60x                      | 52x  | 40x  | 20x  | 18x  |

Table 3: Inference-time efficiency improvements of the Linformer over the Transformer, across various projected dimensions  $k$  and sequence lengths  $n$ . Left table shows time saved. Right table shows memory saved.


+ sharing becov




- По умолчанию attention смотрит на всю последовательность, но действительно ли это необходимо?
- Предлагают использовать локальный attention + глобальный на специальные для задачи токены, например CLS.




(a) Full  $n^2$  attention



(b) Sliding window attention





(c) Dilated sliding window



(d) Global+sliding window

Figure 2: Comparing the full self-attention pattern and the configuration of attention patterns in our Longformer.

# Longformer




| Model                              | #Param | Dev  | Test        |
|------------------------------------|--------|------|-------------|
| <b>Dataset text8</b>               |        |      |             |
| T12 (Al-Rfou et al., 2018)         | 44M    | -    | 1.18        |
| Adaptive (Sukhbaatar et al., 2019) | 38M    | 1.05 | 1.11        |
| BP-Transformer (Ye et al., 2019)   | 39M    | -    | 1.11        |
| Our Longformer                     | 41M    | 1.04 | <b>1.10</b> |
| <b>Dataset enwik8</b>              |        |      |             |
| T12 (Al-Rfou et al., 2018)         | 44M    | -    | 1.11        |
| Transformer-XL (Dai et al., 2019)  | 41M    | -    | 1.06        |
| Reformer (Kitaev et al., 2020)     | -      | -    | 1.05        |
| Adaptive (Sukhbaatar et al., 2019) | 39M    | 1.04 | 1.02        |
| BP-Transformer (Ye et al., 2019)   | 38M    | -    | 1.02        |
| Our Longformer                     | 41M    | 1.02 | <b>1.00</b> |

Table 2: *Small* model BPC on text8 & enwik8

| Model                              | #Param | Test BPC |
|------------------------------------|--------|----------|
| Transformer-XL (18 layers)         | 88M    | 1.03     |
| Sparse (Child et al., 2019)        | ≈100M  | 0.99     |
| Transformer-XL (24 layers)         | 277M   | 0.99     |
| Adaptive (Sukhbaatar et al., 2019) | 209M   | 0.98     |
| Compressive (Rae et al., 2020)     | 277M   | 0.97     |
| Routing (Roy et al., 2020)         | ≈223M  | 0.99     |
| Our Longformer                     | 102M   | 0.99     |

Table 3: Performance of *large* models on enwik8

# DeepSeek: MLA



- Вместо получения  $\mathbf{k}$  и  $\mathbf{v}$  из  $\mathbf{h}$  напрямую возникает промежуточное звено  $\mathbf{c}$ . Кэшируем только  $\mathbf{c}$ !
- Один  $\mathbf{c}$  на все головы, но для каждой головы своя матрица декомпрессии
- Существенная экономия kv cache

$$\begin{aligned}\mathbf{c}_t^{KV} &= W^{DKV} \mathbf{h}_t, \\ \mathbf{k}_t^C &= W^{UK} \mathbf{c}_t^{KV}, \\ \mathbf{v}_t^C &= W^{UV} \mathbf{c}_t^{KV},\end{aligned}$$

$$\begin{aligned}\mathbf{c}_t^Q &= W^{DQ} \mathbf{h}_t, \\ \mathbf{q}_t^C &= W^{UQ} \mathbf{c}_t^Q,\end{aligned}$$



# Linear Attention

$$V' = \text{softmax} \left( \frac{QK^T}{\sqrt{D}} \right) V. \longrightarrow V'_i = \frac{\sum_{j=1}^N \text{sim}(Q_i, K_j) V_j}{\sum_{j=1}^N \text{sim}(Q_i, K_j)}.$$

$$V'_i = \frac{\sum_{j=1}^N \phi(Q_i)^T \phi(K_j) V_j}{\sum_{j=1}^N \phi(Q_i)^T \phi(K_j)}, \longrightarrow V'_i = \frac{\phi(Q_i)^T \sum_{j=1}^N \phi(K_j) V_j^T}{\phi(Q_i)^T \sum_{j=1}^N \phi(K_j)}.$$



- В качестве  $\text{sim}$  может выступать любое ядро, с помощью которого можно вычислять меру схожести, в частности, некоторые ядра могут быть представлены как скалярное произведение двух отображений

$$k(x, y) = \phi(x)^T \phi(y)$$


$$\phi(x) = \text{elu}(x) + 1,$$



# Linear Attention



- Константа по памяти, линейность по вычислениям, однако:
  - Весь контекст сжат в один вектор
  - Для расчета позиции  $t$ , нужен результат всех позиций до
  - Плохо распараллеливается и масштабируется



$$\mathbf{e}_t = \mathbf{E}\mathbf{x}_t$$

$$\mathbf{h}_t = g(\mathbf{U}\mathbf{h}_{t-1} + \mathbf{W}\mathbf{e}_t)$$

$$\mathbf{y}_t = \text{softmax}(\mathbf{E}^T \mathbf{h}_t)$$




# Истоки State Space Models (SSM)

- Базируются на теории управления и обработке непрерывных сигналов (истоки SSM в 1960х!)
- Предназначены для моделирования физических процессов в непрерывном времени (t).
- Система обладает “**состоянием**”, которое хранит историю прошлых воздействий
- Исторически недооценивались в NLP, так как текст является дискретным, а не непрерывным

$$x'(t) = Ax(t) + Bu(t)$$

$$y(t) = Cx(t) + Du(t)$$







# Основная система уравнений SSM

- Первое уравнение - изменение “памяти”
  - A - отвечает за сохранение и забывание прошлого
  - B - влияние текущего сигнала на состояние памяти
- Второе уравнение - формирование выходного сигнала
  - C - влияние текущей памяти на выходной сигнал
  - D - по сути эквивалент skip connection

$$h'(t) = Ah(t) + Bx(t)$$

$$y(t) = Ch(t) + Dx(t)$$



# Дискретизация SSM

- Текст дискретный, мы не можем применять SSM напрямую
- Вводится параметр дискретизации delta + используется некоторое выбранное правило дискретизации
- А при этом хитро инициализируется

(HiPPO Matrix) 
$$A_{nk} = - \begin{cases} (2n+1)^{1/2}(2k+1)^{1/2} & \text{if } n > k \\ n+1 & \text{if } n = k \\ 0 & \text{if } n < k \end{cases}$$

$$h'(t) = Ah(t) + Bx(t)$$

$$y(t) = Ch(t)$$



$$h_t = \bar{A}h_{t-1} + \bar{B}x_t$$

$$y_t = Ch_t$$

$$\bar{A} = \exp(\Delta A) \quad \bar{B} = (\Delta A)^{-1}(\exp(\Delta A) - I) \cdot \Delta B$$

$(\Delta, A, B, C)$  - параметры



# SSM vs RNN: два критических отличия

- В SSM отсутствует нелинейность!
  - Это не ослабляет модель, но открывает новые возможности
- Разное отношение к входным признакам
  - В RNN каналы входного эмбединга смешиваются за счет умножения на плотную матрицу размера  $hs$  на  $hs$
  - В SSM каждая “координата” обрабатывается независимым SSM
    - Соответственно  $h_t$  не вектор, а матрица, например 4096 на 16
    - Отсутствуют большие матрицы 4096 на 4096

$$\mathbf{e}_t = \mathbf{E}\mathbf{x}_t$$

$$\mathbf{h}_t = g(\mathbf{U}\mathbf{h}_{t-1} + \mathbf{W}\mathbf{e}_t) \quad \text{vs} \quad h_t = \bar{A}h_{t-1} + \bar{B}x_t$$

$$\mathbf{y}_t = \text{softmax}(\mathbf{E}^T \mathbf{h}_t) \quad \mathbf{y}_t = C\mathbf{h}_t$$



# Свойство LTI (Linear Time-Invariant)

- **Time Invariant** - у нас веса модели не зависят от входа
- **Linear** - речь именно про линейность в первом уравнении  $h_t$
- Это позволяет рассматривать такие SSM с точки зрения **сверток!** (для обучения)

1. Шаг 0:  $h_0 = \bar{B}x_0$

2. Шаг 1:  $h_1 = \bar{A}h_0 + \bar{B}x_1 = \bar{A}(\bar{B}x_0) + \bar{B}x_1$


3. Шаг  $t$ :  $y_t = Ch_t = C(\dots x_{t-2} + \dots x_{t-1} + \dots x_t)$

$$\bar{K} = (C\bar{B}, C\bar{A}\bar{B}, \dots, C\bar{A}^k\bar{B}, \dots)$$

$$y = x * \bar{K}$$

# Проблема инвариантности ко времени

- Подобные SSM (S4) провалились применительно к тексту, почему?
- В классической непрерывной постановке работает как нужно, но в текстах какие-то слова важнее!
  - Поэтому attention и является основной современных LLM
- Механизм внимания делает нашу систему **контекстно-зависимой** и **селективной**





# Селективная SSM (Mamba-1)

- Добавили **селективность**,  
путем зависимости наших  
параметров от входа
  - То есть добавили новые  
линейные слои
  - Можно отдаленную  
увидеть аналогию с Q K V
- Но мы теряем LTI, а значит и  
сверточный вид и способ  
обучения

$$\begin{array}{lcl} h_t = \bar{A}h_{t-1} + \bar{B}x_t & \longrightarrow & h_t = \bar{A}_th_{t-1} + \bar{B}_tx_t \\ y_t = Ch_t & & y_t = C_th_t \\ & & \downarrow \\ & & B_t = \text{Linear}_B(x_t) \\ & & C_t = \text{Linear}_C(x_t) \\ & & \Delta_t = \text{Linear}_\Delta(x_t) \\ & & \bar{A}_t = f_A(A, \Delta_t) \\ & & \bar{B}_t = f_B(A, B_t, \Delta_t) \end{array}$$



# $\Delta t$ - как основной инструмент селективности

$$h_t = \bar{A}_t h_{t-1} + \bar{B}_t x_t$$

$$y_t = C_t h_t$$

$$\bar{A} = \exp(\Delta A)$$

$$\bar{B} = (\Delta A)^{-1} (\exp(\Delta A) - I) \cdot \Delta B$$

Если мы обрабатываем  
“мусорный” токен

$$\Delta_t \rightarrow 0$$



$$\exp(A \cdot 0) = \exp(0) = \mathbf{1}.$$

$$\bar{B} \rightarrow 0$$



$$h_t = \mathbf{1} \cdot h_{t-1}$$

Если мы обрабатываем  
“очень важный” токен

Большой  $\Delta_t$



$$\exp(-\text{много}) \approx \mathbf{0}.$$




$$h_t = \mathbf{0} \cdot h_{t-1} + \text{Новый факт.}$$



# Блок Mamba-1

- SSM могут быть скомбинированы с другими подходами для формирования блока
- Gated MLP + Selective SSM = Mamba 1




Mamba



# Потеря свертки

- Потеря инвариантности к времени приводит к потере сверточного вида
- Но модель все еще линейная, соответственно свойство ассоциативности
  - Применяется специальный алгоритм parallel scan
- + матрицы  $B_t, C_t, \Delta_t$  не зависят от прошлых шагов, можно считать параллельно



$$h_3 = A_3 \cdot \mathbf{h}_2 + v_3$$

$$h_4 = A_4 \cdot \mathbf{h}_3 + v_4$$




$$h_4 = (A_4 \cdot A_3) \cdot \mathbf{h}_2 + (A_4 \cdot v_3 + v_4)$$

# Hardware-aware parallel algorithm by Tri Dao



Московский  
государственный  
университет  
имени М.В. Ломоносова

## Selective State Space Model *with Hardware-aware State Expansion*





# Mamba результаты

| MODEL             | TOKEN. | PILE<br>PPL ↓ | LAMBADA<br>PPL ↓ | LAMBADA<br>ACC ↑ | HELLASWAG<br>ACC ↑ | PIQA<br>ACC ↑ | ARC-E<br>ACC ↑ | ARC-C<br>ACC ↑ | WINOGRANDE<br>ACC ↑ | AVERAGE<br>ACC ↑ |
|-------------------|--------|---------------|------------------|------------------|--------------------|---------------|----------------|----------------|---------------------|------------------|
| Hybrid H3-130M    | GPT2   | —             | 89.48            | 25.77            | 31.7               | 64.2          | 44.4           | 24.2           | 50.6                | 40.1             |
| Pythia-160M       | NeoX   | 29.64         | 38.10            | 33.0             | 30.2               | 61.4          | 43.2           | 24.1           | <b>51.9</b>         | 40.6             |
| <b>Mamba-130M</b> | NeoX   | <b>10.56</b>  | <b>16.07</b>     | <b>44.3</b>      | <b>35.3</b>        | <b>64.5</b>   | <b>48.0</b>    | <b>24.3</b>    | <b>51.9</b>         | <b>44.7</b>      |
| Hybrid H3-360M    | GPT2   | —             | 12.58            | 48.0             | 41.5               | 68.1          | 51.4           | 24.7           | 54.1                | 48.0             |
| Pythia-410M       | NeoX   | 9.95          | 10.84            | 51.4             | 40.6               | 66.9          | 52.1           | 24.6           | 53.8                | 48.2             |
| <b>Mamba-370M</b> | NeoX   | <b>8.28</b>   | <b>8.14</b>      | <b>55.6</b>      | <b>46.5</b>        | <b>69.5</b>   | <b>55.1</b>    | <b>28.0</b>    | <b>55.3</b>         | <b>50.0</b>      |
| Pythia-1B         | NeoX   | 7.82          | 7.92             | 56.1             | 47.2               | 70.7          | 57.0           | 27.1           | 53.5                | 51.9             |
| <b>Mamba-790M</b> | NeoX   | <b>7.33</b>   | <b>6.02</b>      | <b>62.7</b>      | <b>55.1</b>        | <b>72.1</b>   | <b>61.2</b>    | <b>29.5</b>    | <b>56.1</b>         | <b>57.1</b>      |
| GPT-Neo 1.3B      | GPT2   | —             | 7.50             | 57.2             | 48.9               | 71.1          | 56.2           | 25.9           | 54.9                | 52.4             |
| Hybrid H3-1.3B    | GPT2   | —             | 11.25            | 49.6             | 52.6               | 71.3          | 59.2           | 28.1           | 56.9                | 53.0             |
| OPT-1.3B          | OPT    | —             | 6.64             | 58.0             | 53.7               | 72.4          | 56.7           | 29.6           | 59.5                | 55.0             |
| Pythia-1.4B       | NeoX   | 7.51          | 6.08             | 61.7             | 52.1               | 71.0          | 60.5           | 28.5           | 57.2                | 55.2             |
| RWKV-1.5B         | NeoX   | 7.70          | 7.04             | 56.4             | 52.5               | 72.4          | 60.5           | 29.4           | 54.6                | 54.3             |
| <b>Mamba-1.4B</b> | NeoX   | <b>6.80</b>   | <b>5.04</b>      | <b>64.9</b>      | <b>59.1</b>        | <b>74.2</b>   | <b>65.5</b>    | <b>32.8</b>    | <b>61.5</b>         | <b>59.7</b>      |
| GPT-Neo 2.7B      | GPT2   | —             | 5.63             | 62.2             | 55.8               | 72.1          | 61.1           | 30.2           | 57.6                | 56.5             |
| Hybrid H3-2.7B    | GPT2   | —             | 7.92             | 55.7             | 59.7               | 73.3          | 65.6           | 32.3           | 61.4                | 58.0             |
| OPT-2.7B          | OPT    | —             | 5.12             | 63.6             | 60.6               | 74.8          | 60.8           | 31.3           | 61.0                | 58.7             |
| Pythia-2.8B       | NeoX   | 6.73          | 5.04             | 64.7             | 59.3               | 74.0          | 64.1           | 32.9           | 59.7                | 59.1             |
| RWKV-3B           | NeoX   | 7.00          | 5.24             | 63.9             | 59.6               | 73.7          | 67.8           | 33.1           | 59.6                | 59.6             |
| <b>Mamba-2.8B</b> | NeoX   | <b>6.22</b>   | <b>4.23</b>      | <b>69.2</b>      | <b>66.1</b>        | <b>75.2</b>   | <b>69.7</b>    | <b>36.3</b>    | <b>63.5</b>         | <b>63.3</b>      |
| GPT-J-6B          | GPT2   | —             | 4.10             | 68.3             | 66.3               | 75.4          | 67.0           | 36.6           | 64.1                | 63.0             |
| OPT-6.7B          | OPT    | —             | 4.25             | 67.7             | 67.2               | 76.3          | 65.6           | 34.9           | 65.5                | 62.9             |
| Pythia-6.9B       | NeoX   | 6.51          | 4.45             | 67.1             | 64.0               | 75.2          | 67.3           | 35.5           | 61.3                | 61.7             |
| RWKV-7.4B         | NeoX   | 6.31          | 4.38             | 67.2             | 65.5               | 76.1          | 67.8           | 37.5           | 61.0                | 62.5             |



# Недостатки Mamba-1

- Эксперименты с моделями до 3B показали преимущество Mamba-1 на трансформером!
- Однако, смены парадигмы не произошло
- **Проблема масштабирования обучения** на multi-node кластеры
  - parallel scan плохо переносится на такие системы
  - много процедур синхронизации



# State Space Duality

- State Space Duality (SSD): показали, что SSM и линейное внимание (Linear Attention, некоторые типы) две стороны одной МОНЕТЫ

$$y_4 = \underbrace{(C_4 \bar{A}_4 \bar{A}_3 \bar{A}_2 \bar{B}_1) \cdot x_1}_{\text{Влияние токена 1}} + \underbrace{(C_4 \bar{A}_4 \bar{A}_3 \bar{B}_2) \cdot x_2}_{\text{Влияние токена 2}} + \underbrace{(C_4 \bar{A}_4 \bar{B}_3) \cdot x_3}_{\text{Влияние токена 3}} + \underbrace{(C_4 \bar{B}_4) \cdot x_4}_{\text{Влияние токена 4}}$$


C4 идет можно рассмотреть как “запрос”

$$\text{Attention Score}_{(4,1)} = Q_4 \cdot \text{Маска}_{(4,1)} \cdot (K_1 V_1)$$


- Если токен 3 был невероятно важным, то  $A_3$  у нас  $\rightarrow 0$ , а значит всё “внимание” нашей SSM! на токен 3 и токен 4!
- Чем дальше от токена, тем сильнее “затухает” внимание

# Mamba-2

- Раз у нас SSM можно рассматривать как линейное внимание, то можно и использовать наработки трансформера!
  - + multi head
  - + рост внутренней размерности с 16 до 256
  - + больше матричных умножений, который ложатся на tensor parallel
  - Также A упростили до скаляра
  - Более эффективная реализация



Mamba



Mamba-2





# Mamba-2: результаты

| MODEL               | TOKEN. | PILE<br>PPL ↓ | LAMBADA<br>PPL ↓ | LAMBADA<br>ACC ↑ | HELLASWAG<br>ACC ↑ | PIQA<br>ACC ↑ | ARC-E<br>ACC ↑ | ARC-C<br>ACC ↑ | WINOGRANDE<br>ACC ↑ | OPENBOOKQA<br>ACC ↑ | AVERAGE<br>ACC ↑ |
|---------------------|--------|---------------|------------------|------------------|--------------------|---------------|----------------|----------------|---------------------|---------------------|------------------|
| Pythia-1B           | NeoX   | 7.82          | 7.92             | 56.1             | 47.2               | 70.7          | 57.0           | 27.1           | 53.5                | 31.4                | 49.0             |
| Mamba-790M          | NeoX   | <u>7.33</u>   | <u>6.02</u>      | <b>62.7</b>      | <b>55.1</b>        | <b>72.1</b>   | <b>61.2</b>    | <b>29.5</b>    | <u>56.1</u>         | <u>34.2</u>         | <u>53.0</u>      |
| <b>Mamba-2-780M</b> | NeoX   | <b>7.26</b>   | <b>5.86</b>      | <u>61.7</u>      | <u>54.9</u>        | <u>72.0</u>   | <u>61.0</u>    | <u>28.5</u>    | <b>60.2</b>         | <b>36.2</b>         | <b>53.5</b>      |
| Hybrid H3-1.3B      | GPT2   | —             | 11.25            | 49.6             | 52.6               | 71.3          | 59.2           | 28.1           | 56.9                | 34.4                | 50.3             |
| Pythia-1.4B         | NeoX   | 7.51          | 6.08             | 61.7             | 52.1               | 71.0          | 60.5           | 28.5           | 57.2                | 30.8                | 51.7             |
| RWKV4-1.5B          | NeoX   | 7.70          | 7.04             | 56.4             | 52.5               | 72.4          | 60.5           | 29.4           | 54.6                | 34.0                | 51.4             |
| Mamba-1.4B          | NeoX   | <u>6.80</u>   | <u>5.04</u>      | <u>65.0</u>      | <u>59.1</u>        | <b>74.2</b>   | <b>65.5</b>    | <u>32.8</u>    | <b>61.5</b>         | <u>36.4</u>         | <b>56.4</b>      |
| <b>Mamba-2-1.3B</b> | NeoX   | <b>6.66</b>   | <b>5.02</b>      | <b>65.7</b>      | <b>59.9</b>        | <u>73.2</u>   | <u>64.3</u>    | <b>33.3</b>    | <u>60.9</u>         | <b>37.8</b>         | <b>56.4</b>      |
| Hybrid H3-2.7B      | GPT2   | —             | 7.92             | 55.7             | 59.7               | 73.3          | 65.6           | 32.3           | 61.4                | 33.6                | 54.5             |
| Pythia-2.8B         | NeoX   | 6.73          | 5.04             | 64.7             | 59.3               | 74.0          | 64.1           | 32.9           | 59.7                | 35.2                | 55.7             |
| RWKV4-3B            | NeoX   | 7.00          | 5.24             | 63.9             | 59.6               | 73.7          | 67.8           | 33.1           | 59.6                | 37.0                | 56.4             |
| Mamba-2.8B          | NeoX   | <u>6.22</u>   | <u>4.23</u>      | <u>69.2</u>      | <u>66.1</u>        | <u>75.2</u>   | <b>69.7</b>    | <u>36.3</u>    | <u>63.5</u>         | <b>39.6</b>         | <u>59.9</u>      |
| <b>Mamba-2-2.7B</b> | NeoX   | <b>6.09</b>   | <b>4.10</b>      | <b>69.7</b>      | <b>66.6</b>        | <b>76.4</b>   | <u>69.6</u>    | <b>36.4</b>    | <b>64.0</b>         | <u>38.8</u>         | <b>60.2</b>      |



# Старт гибридов



| Model<br>(avg, max) Ctx. Len: | Single Doc. QA             |                       |                             |                         | Multi-Doc. QA            |                         |                         | Few-Shot Learning     |                          | Avg          |
|-------------------------------|----------------------------|-----------------------|-----------------------------|-------------------------|--------------------------|-------------------------|-------------------------|-----------------------|--------------------------|--------------|
|                               | NarrativeQA<br>(86K, 506K) | Qasper<br>(4.9K, 22K) | MultiFieldQA<br>(7.2K, 17K) | QuALITY<br>(6.5K, 9.8K) | HotpotQA<br>(13.3K, 19K) | 2WikiMQA<br>(7.5K, 17K) | Musique<br>(16.3K, 18K) | TREC<br>(7.1K, 11.9K) | TriviaQA<br>(12.3K, 25K) |              |
| Mamba-2                       | 22.53                      | 25.74                 | 29.26                       | 33.84                   | 29.99                    | 24.6                    | 11.1                    | 54                    | 77.77                    | 34.31        |
| Transformer-4K                | 23.44                      | 28.51                 | 38.39                       | <b>36.48</b>            | 36.28                    | <b>33.48</b>            | <b>17.68</b>            | 68                    | 83.65                    | 40.66        |
| Mamba-2-Hybrid-4k             | <b>24.53</b>               | <b>28.75</b>          | <b>39.01</b>                | 35.6                    | 36.24                    | 32.91                   | 15.24                   | <b>68.5</b>           | <b>86.7</b>              | <b>40.83</b> |
| Transformer-16K               | 27.51                      | 29.71                 | <b>41.13</b>                | <b>39.02</b>            | <b>48.61</b>             | <b>34.87</b>            | 21.42                   | <b>78.5</b>           | 86.39                    | <b>45.24</b> |
| Mamba-2-Hybrid-16k            | <b>29.76</b>               | <b>30.93</b>          | 40.9                        | 38.93                   | 42.17                    | 31.34                   | <b>23.32</b>            | 74                    | <b>90.05</b>             | 44.6         |
| Transformer-32K               | 30.06                      | 29.09                 | 40.61                       | <b>39.17</b>            | <b>48.2</b>              | <b>35.52</b>            | <b>24.55</b>            | <b>76.5</b>           | 86.43                    | <b>45.57</b> |
| Mamba-2-Hybrid-32K            | <b>31.56</b>               | <b>30.55</b>          | <b>40.69</b>                | 38.88                   | 41.9                     | 29.06                   | 21.33                   | 74.5                  | <b>89</b>                | 44.16        |

| Model          | Params (B)                                                | # Layers | Model Dim | Attn. Heads | State Dim. | # Groups | Pos. Emb. | Seq. Len |
|----------------|-----------------------------------------------------------|----------|-----------|-------------|------------|----------|-----------|----------|
|                | 8.66                                                      | 56       | 4096      | 32          | 128        | 8        | None      | 4096     |
| Mamba-2-Hybrid | Hybrid Layer Pattern (M=Mamba-2, *=Self-Attention, +=MLP) |          |           |             |            |          |           |          |
|                | M+M+M++M+M*+M+M+M+M++M*+M+M+M+M+M*++M+M+M+M+M*+M++M+M+M+  |          |           |             |            |          |           |          |



# Delta net - развитие линейного внимания

Формула линейного внимания

$$y^{(i)} = \frac{\sum_{j=1}^i (\mathbf{v}^{(j)} \phi(\mathbf{k}^{(j)})^\top) \phi(\mathbf{q}^{(i)})}{(\sum_{j'=1}^i \phi(\mathbf{k}^{(j')})) \cdot \phi(\mathbf{q}^{(i)})}$$

$\uparrow$   
 $S^{(i)}$

Это наша матрица “памяти”

$$S^{(i)} = S^{(i-1)} + \mathbf{v}^{(i)} \phi(\mathbf{k}^{(i)})^\top$$

Delta net (идеи из 1960х снова)

$$S^{(i)} = S^{(i-1)} + \Delta^{(i)} \phi(\mathbf{k}^{(i)})^\top$$

Где  $\Delta^{(i)}$  вычисляется как:

$$\Delta^{(i)} = \mathbf{v}^{(i)} - S^{(i-1)} \phi(\mathbf{k}^{(i)})$$

# Delta net: результаты




|                    | Update<br>Rule | <i>small</i> |             | <i>medium</i> |             |
|--------------------|----------------|--------------|-------------|---------------|-------------|
|                    |                | Valid        | Test        | Valid         | Test        |
| Transformer        | -              | 33.0         | 34.1        | 27.9          | 29.6        |
| Linear Transformer | sum            | 37.1         | 38.3        | 31.1          | 33.0        |
| Delta Network      | delta          | <b>34.1</b>  | <b>35.5</b> | <b>29.7</b>   | <b>31.5</b> |

Delta net + gates из Mamba-2

$$S^{(i)} = \alpha^{(\mathbf{i})} S^{(i-1)} + \beta^{(\mathbf{i})} \Delta^{(i)} \phi(\mathbf{k}^{(i)})^\top$$

# Gated Delta Net: варианты блоков






# Gated Delta Net: результаты

| Model                             | Wiki.<br>ppl ↓ | LMB.<br>ppl ↓ | LMB.<br>acc ↑ | PIQA<br>acc ↑ | Hella.<br>acc_n ↑ | Wino.<br>acc ↑ | ARC-e<br>acc ↑ | ARC-c<br>acc_n ↑ | SIQA<br>acc ↑ | BoolQ<br>acc ↑ | Avg.         |
|-----------------------------------|----------------|---------------|---------------|---------------|-------------------|----------------|----------------|------------------|---------------|----------------|--------------|
| <i>Recurrent models</i>           |                |               |               |               |                   |                |                |                  |               |                |              |
| RetNet                            | 19.08          | 17.27         | 40.52         | 70.07         | 49.16             | 54.14          | 67.34          | 33.78            | <b>40.78</b>  | <u>60.39</u>   | 52.02        |
| HGRN2                             | 19.10          | 17.69         | 39.54         | 70.45         | 49.53             | 52.80          | 69.40          | 35.32            | <u>40.63</u>  | 56.66          | 51.79        |
| Mamba                             | 17.92          | 15.06         | 43.98         | 71.32         | 52.91             | 52.95          | 69.52          | 35.40            | 37.76         | <b>61.13</b>   | 53.12        |
| Mamba2                            | <u>16.56</u>   | <u>12.56</u>  | <u>45.66</u>  | <u>71.87</u>  | <u>55.67</u>      | <u>55.24</u>   | <b>72.47</b>   | <u>37.88</u>     | 40.20         | 60.13          | <u>54.89</u> |
| DeltaNet                          | 17.71          | 16.88         | 42.46         | 70.72         | 50.93             | 53.35          | 68.47          | 35.66            | 40.22         | 55.29          | 52.14        |
| Gated DeltaNet                    | <b>16.42</b>   | <b>12.17</b>  | <b>46.65</b>  | <b>72.25</b>  | <b>55.76</b>      | <b>57.45</b>   | <u>71.21</u>   | <b>38.39</b>     | <u>40.63</u>  | 60.24          | <b>55.32</b> |
| <i>Attention or hybrid models</i> |                |               |               |               |                   |                |                |                  |               |                |              |
| Transformer++                     | 18.53          | 18.32         | 42.60         | 70.02         | 50.23             | 53.51          | 68.83          | 35.10            | 40.66         | 57.09          | 52.25        |
| Samba                             | 16.13          | 13.29         | 44.94         | 70.94         | 53.42             | 55.56          | 68.81          | 36.17            | 39.96         | <u>62.11</u>   | 54.00        |
| Gated DeltaNet-H1                 | <u>16.07</u>   | <b>12.12</b>  | <u>47.73</u>  | <b>72.57</b>  | <u>56.53</u>      | <b>58.40</b>   | <u>71.75</u>   | <b>40.10</b>     | <u>41.40</u>  | <b>63.21</b>   | <b>56.40</b> |
| Gated DeltaNet-H2                 | <b>15.91</b>   | <u>12.55</u>  | <b>48.76</b>  | <u>72.19</u>  | <b>56.88</b>      | <u>57.77</u>   | <u>71.33</u>   | <u>39.07</u>     | <b>41.91</b>  | 61.55          | <u>56.18</u> |



# Qwen3.5 - гибридная модель!





# Выводы

- Классический **механизм внимания** является крайне высоким “бейзлайном” по **качеству**, из-за отсутствия компрессии контекста
- Для борьбы с **квадратом по времени** и **линейностью по памяти** более 5 лет шли исследования в разных направлениях
- SSM развивались изначально плохо из-за проблем с эффективным вычислением и сложной математикой
- Пришли (сейчас) к гибриднему подходу, когда комбинируется полное внимание и идеи из SSM, линейного внимания, delta net
- **Современные LLM** - это невероятная **комбинация математики и инженерии**, одно без другого не работает